

UNIVERSITÉ DE NOUAKCHOTT
Faculté des Sciences et Techniques

Master 1 Intelligence Artificielle

Rapport de Projet Intégrateur

Pipeline Hybride ML + DL : Classification de Lésions Cutanées (HAM10000)

Extraction de Features Profondes, Réduction PCA
et Classification par Ensemble (XGBoost)

Présenté par :

Mohamed Salem Ebnou Oubeid — C34613
Fatimata Issa Saw — C21304
Oussama Sid'Ahmed Hedy — C34603

Encadreur : Dr. Rivea Sadegh

Date de soutenance : 13 juin 2026

Résumé

Ce rapport présente la conception et l'évaluation d'un pipeline hybride combinant Deep Learning et Machine Learning classique pour la classification de lésions cutanées sur le jeu de données HAM10000 (10 015 images dermatoscopiques, 7 classes). Un MLP est entraîné comme extracteur de features à partir de métadonnées et d'histogrammes de couleurs (42 features) ; ses activations cachées sont réduites par ACP (30 composantes) puis transmises à un classifieur XGBoost. Le pipeline hybride atteint 75,8 % d'accuracy macro en validation croisée 5-fold, surpassant le MLP seul (73,2 %) et XGBoost sur features brutes (62,8 %). L'interprétabilité est assurée par SHAP, et l'incertitude par MC-Bootstrap.

1. Introduction

Le diagnostic précoce du mélanome et des lésions cutanées malignes est crucial. En Mauritanie, l'accès à un dermatologue qualifié reste limité. Le dataset HAM10000 (Tschandl et al., 2018) contient 10 015 images en 7 classes : MEL, NV, BCC, AKIEC, BKL, DF, VASC. Notre objectif est de démontrer qu'un pipeline MLP → PCA → XGBoost surpasse les approches pures tout en offrant interprétabilité (SHAP) et incertitude (MC-Bootstrap).

2. État de l'art

Les méthodes d'ensemble (Dietterich, 2000) combinent plusieurs apprenants faibles pour réduire biais et variance. Sur HAM10000, Thwin & Park (2024) obtiennent jusqu'à 96 % d'accuracy avec un ensemble VGG16 + Inception-V3 + ResNet-50. Asaduzzaman et al. (2025) atteignent 92 % avec un ensemble CNN-SVM. Fiaz et al. (2025) proposent un framework hybride explicable (segmentation + classification) évalué sur HAM10000 avec Grad-CAM.

L'interprétabilité (SHAP, Lundberg & Lee, 2017) et l'incertitude (MC-Dropout, Gal & Ghahramani, 2016) restent des enjeux cliniques majeurs pour l'adoption des systèmes d'aide au diagnostic.

3. Dataset HAM10000

3.1 Description

Caractéristique	Valeur
Total d'images	10 015 images dermatoscopiques
Classes	7 types de lésions cutanées
Résolution	600×450 pixels (RGB)
Métadonnées	Âge, sexe, localisation anatomique, méthode de confirmation
Déséquilibre	NV : 66,9 % · MEL : 11,1 % · BKL : 11,0 % · autres : < 5 %

3.2 Ingénierie des features (42 features)

Type	Description	Nb
Métadonnées	Âge normalisé, sexe (one-hot), localisation (one-hot)	6
Hist. R	Canal rouge, 12 bins normalisés	12
Hist. G	Canal vert, 12 bins normalisés	12
Hist. B	Canal bleu, 12 bins normalisés	12

Type	Description	Nb
Total	—	42

4. Architecture du Pipeline Hybride

- Bloc 1 — MLP extracteur :** 42 → 128 → 64 neurones (ReLU, Dropout 0,3).
Bloc 2 — PCA : 64 → 30 composantes (~85 % variance).
Bloc 3 — XGBoost : 300 estimateurs, lr=0,05, max_depth=6, validation 5-fold.

5. Expériences et Résultats

5.1 Résultats comparatifs

Modèle	Accuracy	F1 macro	Temps
Random Forest (features brutes)	54,1 %	0,487	~8 s
XGBoost (features brutes)	62,8 %	0,571	~12 s
MLP seul (end-to-end)	73,2 %	0,681	~45 s
Pipeline hybride (MLP+PCA+XGBoost)	75,8 %	0,712	~60 s
Stacking (RF+XGB+MLP)	74,3 %	0,698	~90 s

5.2 Résultats par classe (Pipeline hybride)

Classe	Precision	Recall	F1	Support
MEL (Mélanome)	0,68	0,62	0,65	224
NV (Nævi)	0,84	0,88	0,86	1341
BCC (Carcinome basocell.)	0,72	0,69	0,70	103
AKIEC (Kératose actinique)	0,63	0,58	0,60	65
BKL (Kératose bénigne)	0,67	0,64	0,65	221
DF (Dermatofibrome)	0,71	0,55	0,62	22
VASC (Lésion vasculaire)	0,82	0,78	0,80	28
Macro avg	0,72	0,68	0,70	2004

6. Analyse des Confusions Fréquentes

Classe réelle	Classe prédite	Nb erreurs	Cause probable
MEL	NV	38	Similitude morphologique (lésion pigmentée)
BKL	MEL	21	Aspect pigmenté des kératoses séborrhéiques
AKIEC	BKL	14	Chevauchement des features de texture
DF	NV	9	Taille et couleur similaires

7. Interprétabilité par SHAP

SHAP révèle : histogramme canal R (bins 8–10) discriminant MEL/NV ; âge normalisé corrélé avec BKL ; histogramme canal B (bins 0–2) associé aux mélanomes ; localisation (torse) prédictive de BCC.

8. Quantification de l'incertitude (MC-Bootstrap)

T=50 modèles XGBoost entraînés sur sous-échantillons bootstrap. Prédictions correctes → incertitude médiane 0,08 ; erreurs → 0,21 ($\times 2,6$). Le système peut signaler les cas ambigus pour révision humaine.

9. Discussion

9.1 Apports

- Performance : +2,6 pts vs MLP seul, +13 pts vs XGBoost seul.
- Interprétabilité : SHAP applicable à XGBoost.
- Incertitude : quantifiable via bootstrap, utile en contexte médical.

9.2 Limites et perspectives

Les histogrammes ne capturent pas la texture fine ; un CNN pré-entraîné (ResNet-50) serait un meilleur extracteur. Le déséquilibre NV (66,9 %) biaise l'accuracy globale. Perspectives : ResNet-50, LightGBM, application à la rétinopathie diabétique en Mauritanie.

10. Bibliographie

Articles recents (2024-2025, <= 24 mois de la soutenance)

- [1] Tschandl, P. et al. (2018). The HAM10000 dataset. *Scientific Data*, 5, 180161.
- [2] Dietterich, T. G. (2000). Ensemble Methods in Machine Learning. *MCS 2000*, LNCS 1857.
- [3] Chen, T. & Guestrin, C. (2016). XGBoost. *KDD 2016*.
- [4] Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press.
- [5] Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS 2017*.
- [6] Gal, Y. & Ghahramani, Z. (2016). Dropout as a Bayesian Approximation. *ICML 2016*.
- [7] Thwin, S. M. & Park, H.-S. (2024). Skin Lesion Classification Using a Deep Ensemble Model. *Appl. Sci.*, 14(13), 5599. doi:10.3390/app14135599 [2024]
- [8] Asaduzzaman, A., Thompson, C. C. & Sibai, F. N. (2025). Application of ensemble learning models in computer-aided diagnosis of skin diseases. *Neural Comput & Applic.* doi:10.1007/s00521-025-11336-w [2025]
- [9] Fiaz, M. et al. (2025). An explainable hybrid deep learning framework for precise skin lesion segmentation and multi-class classification. *Frontiers in Medicine*, 12. doi:10.3389/fmed.2025.1681542 [2025]
- [10] Chiu, T.-M. et al. (2025). Deep Ensemble Learning for Multiclass Skin Lesion Classification. *Bioengineering*, 12(9), 934. doi:10.3390/bioengineering12090934 (dataset CSMUH).

Transparence — Outils d'Intelligence Artificielle Utilisés

Conformément aux exigences du devoir, cette section documente de manière transparente l'ensemble des outils d'IA et des outils techniques utilisés, en précisant le rôle exact de chacun.

Outils d'Intelligence Artificielle

Outil	Usage dans le projet
DeepSeek	Planification initiale du projet ; structuration du prompt maître décrivant les livrables.
Claude (Anthropic) via Cowork	Génération HTML, notebooks Jupyter, rapports PDF, débogage.
GitHub Copilot	Assistance à l'installation des packages Python et débogage des erreurs de compatibilité.

Outils Techniques

Outil / Technologie	Rôle
HTML / CSS / JS (Vanilla)	Présentation interactive (52 slides, navigation clavier/souris, menu latéral).
KaTeX	Rendu des équations mathématiques LaTeX dans le navigateur.
Chart.js 4.4	Graphiques interactifs (Condorcet, courbes d'apprentissage).
ReportLab (Python)	Génération programmatique des rapports PDF avec en-tête/pied UN-FST.
VS Code / Jupyter / Colab	Environnement d'exécution GPU (Colab) et développement local (VS Code, Jupyter).
GitHub	Versionnement et partage du code source.
scikit-learn / XGBoost / PyTorch / SHAP	Implémentation des algorithmes ML/DL, interprétabilité et incertitude.

Déclaration d'intégrité académique

Tous les contenus scientifiques (théories, démonstrations mathématiques, pseudocodes, analyses de résultats) ont été vérifiés, compris et validés par les membres du groupe avant intégration dans les livrables. Les outils d'IA ont servi de levier de productivité (mise en forme, génération de code boilerplate, structuration documentaire), non de substitut à la compréhension ou à la réflexion scientifique.