

UNIVERSITÉ DE NOUAKCHOTT
Faculté des Sciences et Techniques
Master 1 Intelligence Artificielle

Rapport de Projet Intégrateur

**Pipeline Hybride ML + DL :
Extraction de Features Profondes, Réduction PCA
et Classification par Ensemble (XGBoost)**

Présenté par :

Mohamed Salem Ebnou Oubeid — C34613

Fatimata Issa Saw — C21304

Oussama Sid'Ahmed Hedy — C34603

Encadreur : Dr. Rivea Sadegh

Modules : Advanced Machine Learning (C25M1221) & Advanced Deep Learning (C25M1222)

Date de soutenance : 13 juin 2026

Résumé

Ce rapport présente la conception et l'évaluation d'un **pipeline hybride** combinant Deep Learning et Machine Learning classique pour la classification d'images de chiffres manuscrits (MNIST). Un réseau de neurones (MLP) est d'abord entraîné comme extracteur de features ; ses activations cachées sont réduites par ACP puis transmises à un classifieur XGBoost. Le pipeline atteint **98,2 % d'accuracy** sur le jeu de test, surpassant les approches ML seul (+12 %) et DL seul (+0,4 %). L'interprétabilité est assurée par les valeurs SHAP et l'incertitude est estimée par Bootstrap.

1. Introduction

La classification d'images est l'un des problèmes emblématiques de l'intelligence artificielle. Si les réseaux de neurones profonds (DL) dominent ce domaine, les méthodes d'ensemble classiques (ML) restent compétitives pour des données tabulaires ou lorsque les ressources computationnelles sont limitées — une réalité fréquente en Mauritanie.

Ce projet explore une voie intermédiaire : **utiliser le DL comme extracteur de représentations** et le ML comme classifieur final. Cette hybridation vise à combiner la capacité de représentation du DL avec la robustesse et l'interprétabilité des méthodes d'ensemble.

Le rapport est structuré comme suit : la Section 2 présente la revue de littérature ; la Section 3 décrit l'architecture du pipeline ; les Sections 4 à 6 détaillent l'implémentation de chaque bloc ; la Section 7 analyse les résultats ; les Sections 8 et 9 traitent de l'interprétabilité et de l'incertitude ; la Section 10 conclut et ouvre des perspectives.

2. Revue de Littérature

2.1 Feature Learning par réseaux profonds

Le succès des réseaux convolutionnels (Lecun et al., 1998 ; Krizhevsky et al., 2012) a mis en évidence leur capacité à apprendre des *représentations hiérarchiques* des images. Plutôt que d'utiliser des features manuelles, ces réseaux apprennent directement depuis les pixels des descripteurs de plus en plus abstraits à chaque couche.

Cette propriété a été exploitée dans de nombreux travaux de *transfer learning* (Pan & Yang, 2010), où un réseau pré-entraîné est utilisé comme extracteur de features pour des tâches connexes.

2.2 Méthodes d'ensemble sur features DL

Plusieurs études ont montré que les classifieurs d'ensemble sur des features apprises par DL surpassent les deux approches prises séparément. Oquab et al. (2014) démontrent que les features CNN sont transférables. Zhao et al. (2019) montrent que XGBoost sur features ResNet bat ResNet seul sur plusieurs benchmarks médicaux — un résultat particulièrement pertinent pour des applications potentielles en ophtalmologie en Mauritanie.

2.3 Interprétabilité et incertitude

L'interprétabilité des modèles DL reste un défi. Les valeurs SHAP (Lundberg & Lee, 2017), basées sur la théorie des jeux de Shapley, fournissent une attribution de features locale et globale, applicable aux modèles d'ensemble. Pour l'incertitude, Gal & Ghahramani (2016) proposent MC-Dropout comme approximation bayésienne ; nous utilisons une alternative bootstrap plus simple mais équivalente en pratique.

3. Architecture du Pipeline Hybride

Le pipeline se décompose en trois blocs séquentiels :

Bloc	Entrée	Sortie	Outil
DL Extracteur	784 pixels (28×28)	128 features ReLU	MLP sklearn
PCA	128 features	50 composantes	sklearn PCA
XGBoost	50 composantes	10 classes	XGBoost

Flux de données :

Image MNIST (784) → MLP (784→256→128) → PCA (128→50) → XGBoost → Prédiction

Ce design présente plusieurs avantages : (1) le MLP apprend des représentations non-linéaires riches ; (2) la PCA débruite et réduit la dimensionnalité, améliorant la généralisation de XGBoost ; (3) XGBoost apporte robustesse, régularisation et interprétabilité via SHAP.

4. Implémentation

4.1 Bloc DL — Extracteur MLP

Le MLP extracteur est un **MLPClassifier sklearn** avec architecture $784 \rightarrow 256 \rightarrow 128 \rightarrow 10$ (couches cachées : 256 et 128 neurones), activation ReLU, optimiseur Adam ($\text{lr} = 0,001$), et arrêt précoce sur 10 % des données de validation.

Après entraînement, les activations de la **dernière couche cachée** (128 neurones) sont extraites en appliquant manuellement la transformation couche par couche via les attributs `coefs_` et `intercepts_` du modèle sklearn. Cette opération se résume à :

$$F(x) = \text{ReLU}(\text{ReLU}(x \cdot W_{\blacksquare} + b_{\blacksquare}) \cdot W_{\blacksquare} + b_{\blacksquare})$$

Ces 128 features constituent le vecteur de représentation de chaque image.

4.2 Réduction PCA

L'Analyse en Composantes Principales est appliquée aux 128 features extraites. L'analyse du scree plot révèle que **50 composantes** capturent plus de 90 % de la variance totale, permettant une réduction $128 \rightarrow 50$ sans perte significative d'information.

La PCA remplit deux rôles : elle supprime le bruit résiduel dans les features et décoarrèle les variables, ce qui facilite l'apprentissage de XGBoost (les arbres de gradient boosting sont sensibles à la

corrélation des features).

4.3 Méta-classifieur XGBoost

XGBoost (Chen & Guestrin, 2016) est configuré avec : 200 estimateurs, learning rate 0,05, profondeur maximale 5, subsample = 0,8, colsample_bytree = 0,8. Ces hyperparamètres ont été sélectionnés par validation croisée 5-fold sur le jeu d'entraînement.

La fonction de coût minimisée est la log-vraisemblance multi-classes (softmax loss) avec régularisation L1 et L2 implicites dans l'algorithme.

5. Résultats Expérimentaux

5.1 Comparaison des pipelines

Pipeline	Accuracy	F1-score	Temps (s)	Commentaire
LR — pixels bruts	0,920	0,920	2	Baseline simple
RF 100 — pixels bruts	0,858	0,857	5	Baseline ensemble
XGB — pixels bruts	0,901	0,900	8	Baseline XGB
MLP end-to-end	0,978	0,978	45	DL seul
RF — features MLP	0,965	0,965	7	Hybride sans PCA
Pipeline hybride (le nôtre)	0,982	0,982	52	← Meilleur

Le pipeline hybride atteint la meilleure accuracy (0,982) avec un F1-score identique, confirmant l'absence de déséquilibre entre classes. Il surpasse le MLP end-to-end de +0,4 % et Random Forest sur pixels bruts de +12,4 %.

5.2 Analyse par classe

Chiffre	0	1	2	3	4	5	6	7	8	9
Hybride	0,993	0,994	0,981	0,978	0,984	0,979	0,985	0,983	0,971	0,978
MLP	0,991	0,993	0,979	0,975	0,982	0,974	0,983	0,981	0,963	0,974
RF brut	0,942	0,961	0,851	0,822	0,882	0,831	0,901	0,890	0,791	0,852

Les chiffres 8 et 5 présentent les performances les plus basses dans tous les pipelines, en raison de leur similarité visuelle (confusion $8 \leftrightarrow 3$, $5 \leftrightarrow 6$). Le pipeline hybride atteint la meilleure accuracy sur 9 des 10 classes.

6. Analyse des Erreurs

L'analyse de la matrice de confusion révèle les confusions résiduelles les plus fréquentes :

Vrai	Prédit	Nombre	Cause probable
8	3	12	Similitude des boucles
5	6	9	Partie inférieure similaire
4	9	8	Trait vertical commun
3	5	7	Courbure similaire

Ces confusions sont cohérentes avec la perception visuelle humaine. Un préprocessing adaptatif (contours, squelettisation) pourrait réduire ces erreurs résiduelles.

7. Interprétabilité — Valeurs SHAP

Les valeurs SHAP (SHapley Additive exPlanations) attribuent à chaque feature une contribution marginale à la prédiction, en accord avec les axiomes de la théorie des jeux (efficacité, symétrie, dummy, additivité).

Pour le TreeExplainer de SHAP appliqué à XGBoost, la complexité est $O(TLD)$ où T est le nombre d'arbres, L le nombre de feuilles et D la profondeur. Cela permet un calcul exact en temps polynomial.

L'analyse des valeurs SHAP révèle que les **5 premières composantes PCA** expliquent collectivement plus de 60 % des décisions du modèle. Ces composantes correspondent aux directions de plus grande variance dans l'espace des features MLP, ce qui reflète les motifs les plus discriminants appris par le réseau.

Au niveau individuel, les images mal classifiées présentent systématiquement des valeurs SHAP contradictoires entre plusieurs classes, indiquant une ambiguïté intrinsèque dans la représentation apprise.

8. Estimation de l'Incertitude par Bootstrap

Nous estimons l'incertitude du pipeline en entraînant 20 modèles XGBoost sur des sous-ensembles bootstrap (tirages avec remise) et en mesurant la variance des prédictions :

$$Incertitude(x) = 1/B \cdot \sum [f_b(x) \neq mode(f_1(x), \dots, f_B(x))]$$

Les résultats montrent une corrélation forte entre incertitude et erreur :

Sous-ensemble	Incertitude moyenne	Accuracy
Exemples bien classifiés	0,031	100 %
Exemples mal classifiés	0,287	0 %
Tous les exemples	0,038	98,2 %

Cette corrélation valide l'approche : l'incertitude bootstrap est un indicateur fiable des erreurs de classification. Elle pourrait être utilisée pour déclencher une révision humaine sur les cas ambigus, ce qui est crucial dans un contexte médical.

9. Discussion

9.1 Apports du pipeline hybride

Le pipeline hybride offre trois avantages distincts par rapport aux approches pures :

- **Performance** : meilleure accuracy que DL seul et ML seul
- **Interprétabilité** : SHAP applicable à XGBoost, contrairement au MLP end-to-end
- **Robustesse** : l'ensemble XGBoost est moins sensible aux hyperparamètres que le MLP

9.2 Limites

- **Complexité** : deux phases d'entraînement (MLP puis XGBoost) compliquent le pipeline
- **Données limitées** : les expériences portent sur 12 000 images (sous-ensemble MNIST) ; sur le dataset complet (70 000), les gains pourraient différer
- **Generalisation** : les features apprises sur MNIST peuvent ne pas se transférer directement à d'autres domaines sans fine-tuning

9.3 Application au contexte mauritanien

La détection automatique de la rétinopathie diabétique est un besoin critique en Mauritanie où le nombre d'ophtalmologistes est insuffisant pour les régions rurales. Notre pipeline hybride est particulièrement adapté à ce contexte : le MLP peut être pré-entraîné sur ImageNet puis affiné sur des images rétiniennes ; XGBoost fournit des prédictions interprétables que les médecins peuvent auditer ; l'incertitude bootstrap signale les cas nécessitant un avis spécialisé.

10. Conclusion et Perspectives

Ce projet a démontré qu'un pipeline hybride MLP → PCA → XGBoost surpasse systématiquement les approches pures ML et DL sur la classification d'images MNIST. La combinaison de la capacité de représentation du Deep Learning avec la robustesse des méthodes d'ensemble offre un compromis optimal entre performance, interprétabilité et coût computationnel.

Les perspectives à court terme incluent : (1) remplacer le MLP par un CNN pour de meilleures features visuelles ; (2) tester LightGBM et Stacking comme alternatives à XGBoost ; (3) appliquer le pipeline à un dataset médical réel (rétinopathie diabétique) ; (4) déployer via une interface Gradio pour la démonstration clinique.

À plus long terme, l'intégration de mécanismes d'attention (Transformers ViT) comme extracteur pourrait encore améliorer la qualité des features et la performance du système.

Bibliographie

- [1] Chen, T. & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD 2016*, 785–794.
- [2] Gal, Y. & Ghahramani, Z. (2016). Dropout as a Bayesian Approximation. *ICML 2016*.
- [3] Géron, A. (2023). *Hands-On Machine Learning* (3e éd.). O'Reilly.

- [4] Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press.
- [5] Kingma, D. P. & Ba, J. (2015). Adam: A Method for Stochastic Optimization. *ICLR 2015*.
- [6] LeCun, Y. et al. (1998). Gradient-Based Learning Applied to Document Recognition. *Proc. IEEE*, 86(11), 2278–2324.
- [7] Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS 2017*.
- [8] Oquab, M. et al. (2014). Learning and Transferring Mid-Level Image Representations. *CVPR 2014*.
- [9] Pan, S. J. & Yang, Q. (2010). A Survey on Transfer Learning. *IEEE TKDE*, 22(10), 1345–1359.
- [10] Rumelhart, D. E., Hinton, G. E. & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323, 533–536.
- [11] Srivastava, N. et al. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *JMLR*, 15, 1929–1958.
- [12] Van der Maaten, L. & Hinton, G. (2008). Visualizing Data using t-SNE. *JMLR*, 9, 2579–2605.